

证券客户营销取数智能体

ClientSim Ask · 用一句话取到客户数据，再把结果带进行为推演

2026 华泰证券杯南京大学 AI+ 创新创业大赛 初赛申报书

课题：Agentic 智能问数在客户营销场景的应用

一、项目背景与意义

证券客户营销的日常工作，起点都是一次取数。「把总资产 500 万以上、近三个月有交易、还没配置过权益类产品的客户圈出来」，这是客户经理每周都要提出的需求。但在多数券商里，这句话要走到结果，路径是：业务人员写需求单 → 提给数据团队 → 排队排期 → 数据团队回头确认口径 → 出数。整个过程以天为单位。需求越贴近一线、越口语化，往返确认的轮次越多。赛题要求把这个环节的响应时间从「天」压到「分钟」，让业务人员用自然语言直接取到数。

这件事的难点不在于把一句话翻译成 SQL。真正的难点有三个。第一是口径散落：同一句「活跃客户」，在客户信息表、交易表、资金流水表里可能对应三种定义，模型如果不知道业务口径，写出的 SQL 语法完全正确、结果却与报表对不上。第二是模型幻觉：语言模型会臆造出不存在的表名和字段名，也会把 A 表的字段写到 B 表上，这类错误不会报错，只会安静地给出一个错数。第三是不可复核：只给一个数字，业务人员无法判断它算得对不对，也无法向合规解释这个数是怎么来的。

我们的解法围绕这三件事展开。用元数据作为约束：把九张业务表的表定义、25 个指标口径、11 条业务术语和可调用的工具整理成机器可读的登记表，模型只能在这个范围内写查询，写不出登记表以外的字段。用三层安全围栏作为兜底：结构层拦住写操作与无上限查询，语义层按表校验字段并核验指标是否登记，结果层检查行数、列数与数值合理性。用评测流程作为闭环：50 条标准问句、15 条留出问句与 12 条能力边界问句构成可复现的回归集，逐条与人工编写的对照查询比对，低分项交由模型打分与人工复核。

我们在这个基础上多做了一步。取数只回答「有多少、有多少钱」，而业务人员真正要决策的往往是「如果这么做会怎样」。因此我们把问数结果与客户行为沙

盘打通：取到的客户名单可以直接带进群体行为推演，看这批客户在暴跌行情下对某套沟通策略的反应，包括恐慌峰值、卖出倾向、投诉与流失风险。这条「取数 → 推演」的闭环，是这套系统区别于普通 NL2SQL 工具的地方。

二、项目内容

2.1 产品形态与主场景

作品名称为证券客户营销取数智能体（ClientSim Ask），形态是独立部署的 Web 平台，可通过 API 或微前端嵌入券商既有的 CRM、客服与投顾工作台。主场景对齐赛题三「Agentic 智能问数在客户营销场景的应用」：业务人员用自然语言提问，智能体检索元数据、生成查询、过安全围栏校验后执行，返回结果、口径解释与可执行名单。下游延伸是客户行为沙盘：把取数得到的客户群体带进策略推演，回答取数之后的「下一步如果这么做会怎样」。

2.2 标准闭环

一次取数按五步链路执行，每一步都在界面上可见。第一步理解意图：把自然语言问题映射到已登记的指标与筛选条件，识别不到时明确告诉用户「换个问法」，而不是猜一个数字。第二步检索元数据：按需调用 `metadata.tables`、`metadata.describe`、`metadata.metrics`、`metadata.glossary` 四个工具，取用表结构、指标口径与业务术语，而不是把全部元数据一次性塞进提示词。第三步生成查询：有模型密钥时由模型产出 SQL，无密钥或模型不可用时由确定性规划器生成，两条路径共用同一条执行链路。第四步安全围栏校验：结构层、语义层、结果层三层校验，拦截级问题直接拒绝执行并降级。第五步执行与解释：执行只读查询，返回结果表格、本次用到的表与指标、三层校验结论以及可选的降级说明。取数完成后，结果页提供「用这批客户跑一次推演」的入口，接上沙盘。

2.3 工作台页面

- 数据问答：取数 Agent 主界面，输入自然语言问题，逐步展示理解意图、检索元数据、生成查询、安全围栏校验、执行结果五个环节，拦截时给出命中的规则编号、原因与降级说明。

- 智能任务中心：输入客户经营目标，实时显示规划步骤、工具调用轨迹与执行概览，失败时给出错误码、重试与取消入口。
- 客户洞察中心：按推演期峰值暴露排序的高风险客户队列，配合六维性格雷达、个体动态行为时间轴与一人一策的沟通建议。
- 群体行为沙盘：三套锚点策略的结果对比与参数空间网格搜索的最优组合、五类原型分群布局的传播网络动画回放、逐时间步聚合指标与六类行为倾向分布。
- 策略与审计：策略比较表（净效用 = 避险收益 - 触达成本 - 唤醒成本）、合规发现清单、取数的三层校验记录与执行审计轨迹、候选技能的生成与人工审批。

2.4 数据与规模

平台内真实落库了赛题给出的九张业务表：客户信息、服务经理信息、产品信息、服务关系、公共维、客户持仓、客户资产、客户交易、客户资产流入流出。合成脱敏数据共 13622 行，其中客户 1000 名、服务经理 50 名、产品 20 只、服务关系 1319 条、持仓 2503 笔、交易 5219 笔、资金流水 2489 条，全部按固定种子确定性生成，可通过一条命令幂等重建。元数据层登记 25 个指标与 11 条业务术语，工具层对外暴露 5 个可调用工具。

2.5 当前范围

初赛阶段的范围是：一条完整的取数与推演闭环、九张表的合成数据集、三层安全围栏、三档评测语料与自动化评测脚本。产品推荐适当性预演等第二个业务场景安排在决赛阶段。需要如实说明的是，官方数据集需在保密协议审核通过后发放，初赛阶段我们使用的是自造的合成数据与自造问答对，材料中的准确率均为该口径下的自测结果。

三、技术方案

3.1 元数据设计：表、指标、术语与工具（攻关任务一）

赛题要求定义出 AI 友好的元数据，并说明元数据的组织形式是工具设计，让大模型通过工具获取有效上下文。我们的做法是把元数据拆成四类登记项，每一类都有明确的字段与消费方：表定义给模型看有哪些表，指标注册表给模型看指标怎么算，业务术语表把口语翻译成字段条件，工具目录说明这些元数据可以怎么取。

四类登记项以 TypeScript 常量形式内置在服务端，与数据库表结构同源，避免了「文档写一套、代码做一套」。

表定义覆盖赛题给出的九张表，每张表记录表名、中文名、业务用途，每个字段记录字段名、类型、中文名与业务口径。建表语句由表定义直接生成，安全围栏的列名白名单也从同一份定义派生，因此「文档、建表语句、校验白名单」三处必然一致，不会出现改了建表忘了改白名单的情况。

指标注册表登记 25 个客户营销常用指标，包括客户数、总资产、日均资产、人均资产、持仓市值、持仓笔数、持仓成本、近 90 日与近 180 日交易笔数与金额、净流入、平均持仓收益率、活跃客户数等。每个指标记录唯一英文名、中文名、口径说明、单位、依赖表与参考 SQL 片段。参考片段只是给模型的提示，模型写出的查询仍须通过安全围栏校验；指标口径说明则直接决定了「近 90 日」这类时间窗在哪张表上生效。

业务术语表登记 11 条口语说法及其口径映射，例如高净值客户（总资产不低于 1000 万元）、活跃客户（近 90 日内有交易）、沉默客户（近 90 日内既无交易也无资金流入）、净流入（流入金额减流出金额）、主协办关系（主办承担主要服务责任）。术语定义与合成数据的生成口径保持同源：客群标签字段只按总资产划分，活跃与沉默由交易与资金流水派生，并由单元测试断言两者一致，避免出现「照元数据写 SQL，反而与报表对不上」。

组织形式上，我们没有把上述元数据整体拼进提示词，而是暴露成 5 个可调用工具，由模型按需取用。这样做有三个好处：上下文预算可控，不必为一次简单计数载入九张表的全部字段；模型先看表清单、再看字段、最后取口径，取用过程本身留在审计里，可以复盘它是根据什么信息写出这条查询的；元数据更新后只需改登记表，工具返回值随之变化，不需要动提示词。

工具名	作用	入参
metadata.tables	列出九张业务表及用途，判断该查哪几张表	无
metadata.describe	给出指定表的字段、类型与业务口径	表名
metadata.metrics	列出已登记指标的口径、单位与依赖表	无
metadata.glossary	把业务说法翻译成字段与阈值条件	术语名（可空）
analytics.ask	翻译、校验并执行一次取数，返回结果与解释	自然语言问题

表 1 元数据与取数工具清单（元数据接口 GET /api/analytics/metadata 与模型侧共用同一份定义）

3.2 安全围栏：表、指标、结果的合法性验证（攻关任务二）

赛题要求设计安全围栏模块，包括但不限于表、指标、结果的合法性验证，一方面尽可能减少大模型幻觉，另一方面降低幻觉带来的影响。我们的围栏分三层，每一层的拦截范围都是确定性的规则，不依赖模型自述：结构层判断这条语句能不能执行，语义层判断它引用的表、字段、指标是否存在，结果层判断算出来的数是否合理。

严格程度的分工是有意设计的：出现即拦截的必须是确定性错误（写操作、多语句、未知表、跨表字段、未登记指标），而「可疑但可能正确」的情况只提醒不拦截（行数偏多、金额量级异常、空结果）。如果把后者也做成拦截，正常的长尾查询会被误杀成拒绝服务，业务人员会觉得系统不可用。

规则编号	层次	校验内容	处置
G-STRUCT-01/02	结构	仅允许单条语句、必须以 SELECT 或 WITH 开头	拦截
G-STRUCT-03	结构	禁止 INSERT/UPDATE/DELETE/DROP/ALTER/PRAGMA 等写操作与库级操作	拦截
G-STRUCT-04	结构	禁止在查询中使用注释（注释检测在去掉字符串字面量后进行）	拦截
G-STRUCT-05/06	结构	缺少行数上限时自动补全为 1000；子查询里的 LIMIT 不能顶替外层上限	提醒
G-SEM-01/02	语义	表名必须在九表白名单内（CTE 名放行）；识别不到表直接拒绝	拦截
G-SEM-03	语义	未登记的字段或函数（不在表名、列名、别名与函数白名单内的标识符）	拦截
G-SEM-05	语义	带表前缀的字段必须属于该别名对应的表（别名由 FROM / JOIN 建立）	拦截
G-SEM-04	语义	声明引用的指标必须已登记在指标注册表内	拦截
G-SEM-06	语义	无表前缀的字段必须属于本次查询的表，挡掉「把 A 表字段写到 B 表」；输出别名不计入	拦截
G-SEM-07	语义	使用 CTE 时字段归属校验无法进行，跳过但显式留痕	提醒
G-RES-01/02/03	结果	返回行数、列数上限与空结果提示	提醒
G-RES-04/05/06	结果	金额不得为负、比率不得超出 ±100%、金额量级不得超过 10 万亿	提醒
G-RES-07	结果	客户数不得超过全库客户数（识破多表连接后直接 COUNT(*) 把行数当人数）	提醒
G-RES-08	结果	1:1 表上的聚合与 1:n 明细表并列时提示连接放大风险	提醒

表 2 三层安全围栏规则清单（当前共 21 条规则，覆盖结构、语义、结果三层）

语义层的按表校验是拦幻觉的关键。只做「全部表字段的并集白名单」是不够的：SELECT gender, market_value FROM cust_info 里的 market_value 属于持仓表，字段名本身合法，只有把校验范围收敛到本次查询用到的表才能发现它写错了表。实现上先由 FROM 与 JOIN 子句建立「别名 → 表」映射，再逐个校验带前缀与不带前缀的字段引用。

结果层的客户数锚点用来识破一类特别隐蔽的错误：查询 JOIN 了持仓表之后直接 COUNT(*)，得到的是持仓笔数而不是客户数，SQL 完全合法、结果却差了数量级。围栏以全库客户数为锚点，超过即提醒「把行数当成了人数」，把这类错误从「安静地给出错数」变成「显式可见」。

命中拦截级规则时，该条查询不执行。如果这条 SQL 来自模型，系统会自动降级到确定性规划器重新生成一条查询并再次过围栏，同时在响应与界面上标注降级原因；两条路径都无法回答时，明确返回「换个问法」，不猜数字。所有命中记录连同规则编号、命中片段与处置方式写入审计。需要如实说明的是：结果层目前只提醒不拦截；面向话术文本的合规审查（承诺收益、诱导操作等 19 条规则）位于下游沙盘的 Policy Gateway，不在取数链路上。

3.3 评测流程：子 agent 打分与人工复核（攻关任务三）

赛题要求设计取数评测流程，并给出最终执行准确率的验证方式。我们的评测由三档语料组成：50 条标准问句按赛题口径分简单（单表单指标、单表多指标）、中等（多表单指标）、复杂（多表多指标、跨主题域）三档；15 条留出问句用另一套说法检验「换个问法还准不准」；12 条能力边界问句是口语化或超出元数据覆盖面的问题，用来测量系统会不会「一本正经地答错」。

判定口径在看结果之前就固定下来：数值类指标按相对误差不超过 2% 视为一致；分组类结果按分组标签对齐，人工对照查询里出现的每个分组都必须在结果中数值一致；边界集判定的是「是否明确拒答」而不是答对。基准值由人工编写的对照查询在同一份数据上执行得到，而不是拿实现里的常量当真值——这一点很关键，否则评测就变成了拿实现验证实现，恒为满分。

评测脚本逐条执行并输出总体准确率、分档准确率与失败明细，结果写入 artifacts/metrics 目录。低分项交给子 agent 打分（模型对生成的查询与对照查询的差异给出评分），再由人工通过 POST /api/analytics/review 记录复核结论，用于统计复核工作量的下降比例。

语料	条数	结果
标准问句（样本内）	50	执行准确率 100%（简单 18/18、中等 18/18、复杂 14/14）
留出问句（另一套说法）	15	执行准确率 100%（简单 5/5、中等 6/6、复杂 4/4）
能力边界问句	12	正确拒答 100%（12/12）

表 3 取数评测结果（版本 v0.2.0，数据快照 2026-09-18，合成数据 1000 名客户，规则路径）

必须如实说明评测的局限。第一，三档语料都是团队自造的，官方问答对需在保密协议审核通过后发放，因此上述数字是自造数据与自造语料上的自测结果，不能外推为真实数据集上的准确率。第二，样本内语料在开发过程中被反复运行过，数字偏乐观，留出集与能力边界集是更诚实的参照；边界集曾出现一类缺口——问题里出现「客户」但问的是九张表里根本没有的主题（投诉、满意度），兜底逻辑会给出一个客户总数。已改为维护一张域外词表，命中即明确拒答，本轮实测 12 条全部正确拒答。第三，目前是未接入模型密钥的规则路径实测，模型路径的主路径指标需在密钥就绪后重跑。第四，样本内与留出集的 100% 都建立在自造语料体系内；团队另用一批不在语料里的口语化问法做过泛化探针，能答对的比例明显更低，这说明「语料上的 100%」只代表确定性可复现，不代表开放问法的能力上限。第五，规则路径仍有已知限制（均以保证不出错为先）：两张明细表并列的多指标问法（如「持仓市值与交易金额」）、人均口径与多指标跨表组合、以及非总资产口径的数值阈值（如「持仓市值超过 100 万的客户」）这三类问题需要更完整的改写能力，目前改用拒答；未枚举的口语化限定条件通过意图词表拒答，词表之外的写法仍可能退回客户总数；CTE 内部的跨表幻觉字段无法按表校验，已用 G-SEM-07 提醒写入审计；结果层校验只提醒不拦截。第六，评测过程中发现 3 条人工对照查询本身存在连接放大缺陷（q24、q41、q40），已修订并留痕；这说明基准值必须能独立复算，不能默认人工写的就一定对。第七，以上结论针对规则路径；模型路径需在密钥就绪后用同一批问法复测，围栏新增的 G-RES-08 会对「1:1 表聚合与

1:n 表并列」的写法给出连接放大提醒（仅提醒不拦截）；另有「总资产超过 X 的客户的总资产与 A」这类句式会少答一列，属完整性缺口，已返回的数字本身正确。

3.4 系统分层

系统自上而下分为五层。产品体验层是 React 与 TypeScript 实现的工作台，通过 SSE 订阅真实执行进度。Harness 层是智能体底座，统一管理工具注册、记忆、权限、执行流程与审计留痕。行为模拟层是确定性 TypeScript 数值引擎，负责客户生成、关系网络与逐时间步状态更新。合规与数据层承载规则引擎、适当性矩阵与持久化。集成层对外提供稳定接口，并预留券商系统对接与多租户权限的位置。



图 1 系统架构：五层分层与各层职责

3.5 Agent Loop 与 Harness 分工

Harness 由六个部件组成。Planner 把自然语言目标翻译成结构化步骤与工具序列；Executor 逐步执行并把每一步的输入输出落库；Tool Registry 注册八个工具，覆盖场景抽取、客户查询、画像构建、关系网络构建、策略起草、模拟执行、合规审查与报告生成；Memory 保存结构化画像与会话记忆摘要；Reflector 在任务成功后评估结果并沉淀候选技能；Policy Gateway 是模型的硬边界，其草稿级拦截前置

一次完整任务的执行时序是：接收目标后先下发第一个进度事件，再进入模型调用；工具链接顺序推进，策略草稿先过 Policy Gateway，命中阻断级规则时被强制改写为合规版本，同时清除该违规话术在模拟中的情绪放大通道，随后才进入群体行为模拟；最后生成结构化报告与反思摘要，候选技能进入人工审批队列。



图 2 Agent Loop 执行时序与 SSE 事件序列

需要说明的是，上面这条八步链路是任务成功时的完整路径，不是写死的工作流。**Planner** 拿到的是目标与可用工具清单，由它决定用哪些工具、按什么顺序调用；下面的三种情形说明执行过程确实存在判断与调整。

- 工具可跳过：目标中不含客群限定时，**Planner** 不会生成客户筛选步骤；只需要看当前群体状态时，模拟与合规仍会执行，但报告步骤可以省略汇总以外的章节。工具序列因此不是恒定八步。
- 结果可触发重规划：客户筛选命中数量不足目标客群规模时，执行器不会直接报错，而是按回撤从高到低补足，并在界面与审计中标注命中不足与补足数量；该情形下筛选步骤的审计状态标为待确认，而不是已完成。
- 失败可回退重试：合规审查命中阻断级规则时，策略草稿被改写为合规版本并重新进入检查；单个步骤调用超时会按指数退避重试，上限两次。若模型输出格式不合格，规划结果退回内置模板并记录降级原因，任务继续而不是中断。

上述分支在审计轨迹中留有痕迹：每一步记录状态（已完成、待确认、已拦截）与真实时间戳，重试会单独产生 `step.failed` 事件。评委可以据此区分「按计划执行」与「执行过程中改变了计划」。

3.6 五层链路

从数据到技能沉淀的产品链路共五层。真实客户画像层把脱敏的交易、持仓、服务记录与反馈沉淀为分群口径；虚拟客户生成层按画像聚类生成五类原型客户；策略模拟层输入候选策略并按时间步推演群体反应；合规边界层执行适当性校验与强制拦截；反思进化层把真实服务结果回流用于校准，并把优秀的编排沉淀为可复用技能。当前第五层的回流依赖真实数据，在数据到位前以人工反馈与候选技能的形式部分实现。



图 3 从真实画像到技能沉淀的五层链路

3.7 群体行为模拟的数学模型

本节给出引擎的完整计算过程。前几节说明的是模块之间怎么连接，真正决定数值结果的是这里的计算。整体顺序是：读取场景参数 → 筛选目标客户 → 生成初始状态 → 建立关系网络 → 按时间步循环更新 → 换算行为倾向并汇总成群体指标与干预队列。以下记客户 i 在第 t 个时间步的恐慌为 $p_i(t)$ ，场景跌幅的绝对值为 s ，涉及的六项心理参数分别为损失厌恶 λ 、从众敏感度 h 、收益追求 a 、投资纪律 d 、长期耐心 k 与机构信任 $trust$ ，取值均在 0 到 1 之间。

第一步是把市场跌幅落到每个客户身上。系统不让所有客户承受同一个跌幅，而是先由心理特征与所持产品算出各自的持仓弹性，再据此得到回撤。

① 持仓弹性与个体回撤

$$\beta_i = \text{clamp}(0.62 + 0.42 \cdot a_i + 0.24 \cdot h_i - 0.16 \cdot d_i + 0.55 \cdot (v_i - 1) + \eta_i, 0.35, 1.9)$$
$$DD_i = \text{clamp}(s \times 100 \times \beta_i + \xi_i, 0.4, 45)$$

v_i 为该客户所持产品的波动系数， η_i 、 ξ_i 是按随机种子生成的个体扰动。含义是：市场跌 1%，这位客户实际承受多少，由他自己的收益追求、从众倾向、纪律水平决定，再叠加产品本身的波动。同一个客户在不同行情下跌幅成比例；同一场行情下不同客户跌幅不同。

第二步是初始状态。客户在行情开始前已有一定恐慌，并在此后按时间步演化。

② 初始恐慌与冲击落地

$$p_i(0) = \text{clamp}(0.1 + 0.35 \cdot \lambda_i + 0.12 \cdot h_i + DD_i/100 - 0.18 \cdot d_i)$$
$$p_i \leftarrow \text{clamp}(0.42 \cdot p_i(0) + s \cdot (0.72 + 0.78 \cdot \lambda_i) - 0.05 \cdot d_i)$$

第二行表示行情冲击真正打进来的那一步：原有恐慌只留 42%，主体来自按损失厌恶加权的市场冲击。

第三步进入时间步循环。每一步先计算当步的行情压力，再计算邻居传导，最后合成新的恐慌。

③ 当步行情压力

$$S(t) = (0.095 + 0.82 \cdot s) \times \text{shape}(H, t/(T-1))$$
$$\text{shape} = \text{clamp}(\ln(\max(H, 1)/24) / \ln 24, -1, 1) \text{ 的线性函数}$$

H 为持续时间（小时）， T 为总段数。持续时间越长， shape 越大，压力衰减越慢。需要如实说明：在该函数的取值范围内压力随步长单调递减，因此恐慌峰值恒定出现在第一段，时长的影响体现在峰值高度与衰减速度，而不是峰值位置。

④ 邻居情绪传导

$$C_i(t) = [\sum_j w_{ij} \cdot p_j(t-1) / \sum_j w_{ij}] \times h_i \times (0.16 + 0.55 \cdot s)$$

w_{ij} 是客户 i 与 j 之间的三类关系权重：相似性 0.72、社交影响 1.0、统一服务触达 0.42 至 0.58。括号内一项表示行情跌得越深，情绪传导越快。这一项是「从众效应」在模型中的具体形式，也是本项目区别于单客户画像工具的关键所在。

⑤ 逐时间步恐慌更新

$$p_i(t) = \text{clamp}(0.56 \cdot p_i(t-1) + S(t) \cdot \lambda_i + C_i(t) + A_i(t) + W_i(t) - B_i(t) - 0.09 \cdot d_i - 0.045 \cdot k_i + \varepsilon_i)$$

七项含义：0.56 是上一段恐慌的留存比例（对应记忆层）； $S(t) \cdot \lambda_i$ 是按损失厌恶加权的市场压力； $C_i(t)$ 是邻居传导； $A_i(t)$ 是广播式沟通引起的额外警觉； $W_i(t)$ 是主动触达本身惊动平静客户的唤醒效应； $B_i(t)$ 是主动沟通的安抚；投资纪律与长期耐心起自我抑制作用； ε_i 是幅度 ± 0.0175 的随机扰动。

第四步把恐慌换算成可执行的行为倾向。四项倾向都用 logistic 函数把线性组合压缩到 0 到 1 之间。

⑥ 行为倾向换算

```
selli      = clamp( σ( (pi - 0.58)·5.2 + 0.7·hi - 1.1·di ) )
buyi      = clamp( σ( (0.34 - pi)·4.4 + 1.2·ai + 0.35·trusti ) × 0.58 )
holdi     = clamp( 1 - buyi - selli )
consulti  = clamp( σ( (pi - 0.32)·3.4 + 0.65·trusti - 0.25·di ) × 0.72 )
complainti = clamp( σ( (pi - 0.62)·4.2 - 2.3·trusti + 7·tone ) × 0.42 )
churni    = clamp( σ( (0.45 - trusti)·5 + 2.2·complainti ) × 0.38 )
```

σ 为 logistic 函数。买入、持有、卖出三项恒之和为 1，因此三者可以直接比较。tone 为该策略话术的刺激强度，若草稿被合规拦截则置零。投诉与流失由恐慌和信任共同决定，不单独受话术影响。

最后是汇总。每个时间步结束后对所有客户取均值，得到该步的群体恐慌、卖出、投诉、流失、信任、触达覆盖与传播强度；同时逐客户记录整个模拟期内的峰值暴露（peakRisk 及其所在段），用于生成干预队列，而不是用期末状态排序——因为干预生效后期末状态会普遍回落，按期末值排序会得到一份人人低风险的名单。

3.7.1 六项心理参数：含义、取值与校准

六项心理参数是引擎的行为输入，它们决定每位客户对同一场行情作出多大反应。当前取值来自五类客户原型，同原型内再叠加 ±0.08 的个体抖动，保证同类客户之间仍有差异。

参数	主要影响	当前取值来源	真实数据接入后的校准方式
损失厌恶 λ	市场压力加权、初始恐慌、安抚需求强度	按原型设定：稳健守成型 0.84 最高，进取交易型 0.34 最低	用真实客户在亏损区间内的减仓与赎回行为与亏损幅度的关系拟合
从众敏感度 h	邻居情绪传导强度、卖出倾向、网络影响力	按原型设定：高频敏感型 0.81 最高	用客户在群体性事件中的同向交易占比拟合
收益追求 a	持仓弹性、买入倾向	按原型设定：进取交易型 0.86 最高	用客户实际持仓的风险等级分布与换手率拟合
投资纪律 d	恐慌的自我抑制、卖出倾向、持仓弹性	按原型设定：稳健守成型 0.82 最高	用回撤期间未发生交易的比例拟合
长期耐心 k	恐慌的自我抑制、沟通节奏偏好	按原型设定：进取交易型 0.31 最低	用客户实际持有期限分布拟合
机构信任 trust	投诉与流失倾向、咨询倾向、信任回复速度	按原型设定：沉默流失型 0.31 最低	用服务触达记录、投诉标签与流失标签拟合

表 4 六项心理参数的含义、当前取值来源与后续校准方式

需要如实说明：当前六项参数全部是合成数据下的工程设定，不是对真实客户的心理测量结果。它们的作用是让不同客户对同一场行情产生方向与幅度都合理的差异，而不是宣称刻画了真实客户的心理。真实数据接入后，上表第四列的校准工作才开始，届时需要重新拟合参数分布并同步更新本材料中的指标与结论。

3.7.2 模型参数的性质与来源

上面出现的系数并非同一类东西，如实区分它们的来源，有助于判断这套模型的可靠边界。

类别	典型参数	来源与依据
结构性系数	恐慌留存 0.56、邻居传导对从众敏感度的线性依赖、买入持有卖出归一	模型结构本身的设定，决定「记忆会累积」「情绪会传导」这两条性质是否成立。改动它们会改变模型的行为方式，而不是微调数值。
标定系数	传播增益 $0.16 + 0.55 \cdot s$ 、行情压力 $0.095 + 0.82 \cdot s$ 、抑制系数 0.09 与 0.045	为满足「冲击越大传导越快、持续越久压力越慢」等单调性质而标定，经 630 个场景扫描确认方向一致。它们不是从真实数据拟合得到的。
业务设定参数	效用权重（避险 1、触达成本 0.1、唤醒成本 2）	避险收益与触达成本量纲不同，两者的兑换率无法从数据中估计，只能由业务方按经营口径设定。材料中同时给出该权重的敏感性曲面。
合成设定	六项心理参数的基线取值、五类客户原型的占比	当前为合成数据下的工程设定，不是真实客户心理测量值。真实数据接入后需要重新拟合并更新指标。

表 5 模型中各类参数的性质与来源

3.7.3 时间步循环伪代码

输入：场景（跌幅 s 、时长 H 、客户数 N 、段数 T 、种子 $seed$ 、客群口径）	
随机数发生器 $rng \leftarrow \text{mulberry32}(seed)$	# 确定性，保证可复现
客户池 $\leftarrow$ 生成候选客户(rng)；目标客户 $\leftarrow$ 按口径筛选(客户池, s)	# 命中不足时按回撤降序补足并标注
对每个客户 i ：计算 β_i 、 DD_i 、初始恐慌 $p_i(0)$	# 公式 ①②
关系网络 $\leftarrow$ 生成三类关系边(目标客户, $seed$)	# 相似性 / 社交影响 / 统一服务触达
邻接表 $\leftarrow$ 建邻接表(关系网络)	

```

对  $t = 1 \dots T$ : # 公式 ③④⑤
    记录上一步恐慌快照  $previous \leftarrow \{p_i(t-1)\}$  # 传播只用上一步状态，避免同一步内串行影响
    计算当步行情压力  $S(t)$ 
    对每个客户  $i$ （并行无关，逐一更新）：
        计算触达门控  $reached_i(t)$  # 覆盖率  $\times$  风险聚焦  $\times$  人工爬坡
        计算邻居传导  $C_i(t)$ ；计算安抚  $B_i(t)$  与唤醒  $W_i(t)$ 
         $p_i(t) \leftarrow \text{clamp}(0.56 \cdot p_i(t-1) + S(t) \cdot \lambda_i + C_i(t) + A_i + W_i - B_i - 0.09 \cdot d_i - 0.045 \cdot k_i + \epsilon_i)$ 
        更新信任  $trust_i$ ；换算 sell / buy / hold / consult / complaint / churn # 公式 ⑥
        若  $riskScore(i) > peakRisk(i)$ ：更新  $peakRisk(i)$  与  $peakStep(i)$ 
# 峰值暴露
    汇总该步群体均值，写入快照（用于回放与指标曲线）

```

按 $peakRisk$ 降序生成干预队列与优先级（高 ≥ 0.45 / 中 ≥ 0.30 ）

按快照序列计算恐慌峰值、期末卖出 / 投诉 / 流失 / 信任，跑三套方案并比较

整段计算不依赖模型输出，因此同一场景与随机种子必然得到相同的聚合结果；模型只影响任务规划、参数抽取与话术措辞，不影响上述任何数值。

3.8 合规规则引擎

合规检查由 19 条注册式规则组成，每条规则带有编号、严重级别、作用范围、匹配模式与是否启用否定语境识别。规则覆盖收益承诺与保本表达、诱导性紧迫表达、替客户做决定、内幕信息与未公开信息、适当性越级推荐、风险揭示缺失、绝对化用语与隐私字段外泄等类别。规则引擎额外维护一份客户风险等级与产品风险等级的适当性矩阵，当推荐的产品风险高于客户承受等级时直接拦截。

否定语境处理是本项目的重点细节。诸如我不会催促您立即操作，也无法承诺收益这类表述在字面上命中了诱导性紧迫表达与收益承诺两类模式，但语义上是合规的免责说明。规则引擎在命中位置附近识别否定词与免责结构，将这类命中降级为提示记录，避免出现把合规话术误判为违规的情况。

规则引擎的判定结果直接构成审计材料。每条发现记录规则编号、严重级别、所属策略、命中片段、字符区间、规则版本与处置状态，状态分为已拦截、待审批

与通过三类。命中阻断级规则时，Policy Gateway 终止该策略的继续执行并写入审计，模型无法绕过这一层。同一套规则集同时服务于群体模拟流程与独立的合规检查接口，避免出现两套口径。

3.9 异步任务、实时进度与失败降级

任务提交接口在写入任务记录后立即返回 202 与任务编号，实际执行在后台进行，本地环境不支持的运行能力会退化为同步执行，但事件照常落库，功能不缺失。进度接口以 SSE 增量推送任务状态、步骤开始与完成、模拟快照、合规发现以及任务完成或失败事件，并带 15 秒心跳。第一个事件固定在场景抽取步骤开始时下发，先于任何模型调用，因此首帧反馈时间与模型延迟解耦。

任务支持取消、重试与超时降级。取消请求在当前步骤边界生效；任务级重试上限为 2 次并采用指数退避；默认 90 秒无进展判定为超时。模型超时与不可用、输出格式错误、模拟失败三类异常都有明确的状态与错误码，并且都会给出确定性的降级结果，界面同步展示错误码、重试与取消入口。知识检索路径另有一条独立判定：当知识库命中不到相关内容时判定为知识缺失（KNOWLEDGE_MISSING），显式降级为无检索并在说明中标注，不静默返回空结果。

3.10 能力边界

明确划分三类职责是这套设计能够同时满足可复现性与合规性的前提。模型侧负责目标理解、任务规划、场景参数抽取、候选策略与话术生成以及结果解释；数值引擎侧负责客户生成、关系网络、逐时间步群体模拟、聚合指标与峰值暴露统计；硬边界侧负责合规判定、适当性校验、阻断改写、审计留痕与人工审批。界面与报告中不展示任何原始思维链，只展示因素权重、数据证据、规则命中与结构化执行轨迹。

四、已有成果与指标

4.1 取数 Agent 实测

取数链路的实测覆盖三类指标。执行准确率见 3.3 节，这里补充运行与校验侧的实测数字。端到端延迟在本地环境连续提问测得：首次请求 1112 毫秒（包含建

表与 13622 行合成数据装载），随后同类查询稳定在 7 至 9 毫秒，远低于赛题要求的分钟级；这一延迟与模型无关，因为规则路径不产生模型调用。安全围栏的强度由负例单元测试守护，跨表幻觉字段、CTE 误拦、子查询行数上限顶替、结果层荒谬值、函数白名单过窄、字符串中的注释符六类场景各有断言，全部通过。

实测项	结果	结论
九张表合成数据规模	13622 行（客户 1000、持仓 2503、交易 5219、资金流水 2489）	通过
首次取数端到端耗时	1112 毫秒（含建表与数据装载）	通过
后续取数端到端耗时	7 至 9 毫秒	通过
安全围栏与规划器边界用例	围栏负例 24 条与规划器行为 26 条，全部通过	通过
自动化测试总数	152 项，覆盖元数据一致性、三层围栏、取数规划与推演引擎	通过
静态检查、类型检查与构建	全部通过	通过

表 6 取数 Agent 运行与校验实测（版本 v0.2.0，本地环境，规则路径）




图 4 数据问答：五步执行链路、实际执行的查询与安全围栏校验结果

4.2 推演链路完成情况

项目当前已完成五个核心页面、确定性客户生成、三套锚点策略与参数空间搜索、三类关系网络传播、合规发现、审计轨迹、报告导出与完整的 API 层，并配置了 SQLite 兼容的持久化，托管版本使用 Cloudflare Workers 与 D1。自然语言中的跌幅、持续时间、客户规模、时间步与随机种子均会进入结构化场景配置，进而影响模拟、持久化、审计与报告。前端任务执行已切换到服务端接口，并在服务端不可用时提供同版本引擎的确定性本地降级。工程侧建立了自动化回归测试，共 152 项用例覆盖确定性、参数敏感性、分群筛选、行为倾向约束、场景抽取边界、沟通策

略参数空间、结论对效用权重的稳健性、合规硬边界因果性、技能沉淀与复用、合规语料召回与误拦截以及任务生命周期；静态检查、类型检查与构建均通过。

本节所有指标由脚本自动生成，记录在版本为 v0.2.0、规则版本为 compliance-rules@2026.09 的指标快照中。指标体系使用合成脱敏数据，随机种子为 20260830。

4.3 验收指标对照

下表为本轮的对外指标。其中第 1 项的口径需要特别说明：未接入模型密钥时规划走内置模板，因此它是流水线冒烟测试，不代表模型的规划能力；第 7 项的策略夺冠分布是本轮新增的关键证据。

验收项	目标	实测	结论
标准任务工具链完整率	不低于 90%	100%	通过
标准任务工具调用成功率	不低于 90%	100%	通过
标准任务场景抽取一致率	不低于 90%	100%	通过
模型规划产出被采纳占比	记录值	未接入模型，待测	待测
300 名客户 10 个时间步引擎耗时	低于 30 秒	15 毫秒级（多次采样 11—26 毫秒）	通过
1000 名客户 20 个时间步引擎耗时	低于 30 秒	70 毫秒级（多次采样 59—82 毫秒）	通过
沟通策略夺冠分布与权重敏感性	记录值	48.9% / 26.3% / 24.8% （权重从 2 调到 0 时变为 1.3% / 84.8% / 14.0%）	通过
相同场景与种子复现	聚合签名一致	一致	通过
跌幅由 10% 增至 30%	恐慌、卖出、流失 不反向下下降	单调成立	通过
持续时间由 24 小时增至 72 小时	峰值不下降	19.3% 增至 19.8%	通过
禁止性合规样例召回率	不低于 95%	100%	通过
待复核合规样例召回率	记录值	90%	通过
合规误拦截率	不高于 10%	0%	通过
首次进度反馈	低于 2 秒	0.35—0.6 秒（视环境负载）	通过

表 7 验收指标对照（版本 v0.2.0，规则版本 compliance-rules@2026.09，种子 20260830）

4.4 沟通策略建模与推荐

三套沟通策略（不主动沟通、统一风险提示、分群差异化沟通）由三个可调杠杆定义，其余引擎参数由杠杆推导，避免出现互相矛盾的独立常数：触达覆盖率决定事件窗口内最终能触达的客户比例；人工深度从纯自动消息到逐人人工沟通，决

定人工作业的爬坡步数与单位成本；内容个性化决定通用话术对风险两端客户的失配程度。安抚只对真正触达的客户生效，即逐客户门控，因此覆盖率是真实输入而不是展示用数字。

推荐顺序由净效用在每个场景里算出来，不是由常数写死的：净效用 = 避险收益 - 触达成本 - 唤醒成本，其中避险收益以「不主动沟通」为参照系，由恐慌峰值、卖出、流失与投诉四项改善加权得到；触达成本按人工深度折算，一次人工沟通的等效成本约为一条自动消息的数十倍；唤醒成本刻画主动触达本身惊动平静客户的代价。效用权重可由业务目标决定，例如预算收紧时提高成本权重，推荐会自动从深度干预移开。

三套锚点只是「触达覆盖率 × 人工深度 × 内容个性化」参数空间里的三个点，引擎另外在该空间做网格搜索，给出净效用更高的参数组合。默认场景下搜索结果优于全部三套锚点，界面会同时展示网格评估点数、最优组合与效用的三项归因分解，便于业务方核对推荐理由。

为验证这套建模确实让结论随场景变化，我们做了 630 个场景的验收扫描（跌幅 7 档、时长 5 档、步数 3 档、随机种子 3 个、客群口径 2 种）。需要如实区分两类结论。第一类是与效用权重无关的结构性质，这是我们的主要验收对象：跌幅越大、推荐方案的人工深度不下降（90 条场景序列零违反）；微跌（5%）不推荐高人工深度方案；重挫（50%）不推荐放弃触达的方案；同种子完全复现；每次推荐都带三项归因分解。这些性质在设计上要求跨权重成立，因此可以失败、有信息量；实测它们在默认与中等效用权重下全部成立，在极端干扰权重下存在一处已定位的边界，见下文。第二类是与效用权重相关的夺冠配比：三种锚点各自夺冠 48.9%、26.3%、24.8%，但这是业务效用权重的函数而不是引擎的固有性质——把唤醒权重从 2 调到 0，不主动沟通的夺冠占比会从 48.9% 降到 1.3%。因此本申报书只把配比连同权重敏感性曲面一起引用，不作为「结论不写死」的证据。已知边界：把干扰权重取到极端值（8）且时长压到 6 小时时，40% 到 50% 的区间会出现一次深度回落，推荐由分群沟通回到统一风险提示。实测机制是：唤醒罚分本身随恐慌上升而衰减（wake = 唤醒系数 × (1 - 上一步恐慌) × 本步新增触达），而 λ_wake 把它放大了 8 倍；广播式的唤醒基数更大，因此衰减带来的减负也更多（实测 50% 档广播式的唤醒罚分比 40% 档低约 42%），而人工成本不随恐慌衰减，于是推荐在高冲击

档翻回低成本的广播式。需要特别指出：恐慌并未饱和（该场景峰值约 58%–84%（扫描脚本同组参数下 40% 档为 57.5%/62.5%/68.4%，50% 档为 70.4%/76.5%/83.8%），明显低于上限 1.0），因此这**不是**饱和效应。该配置不属于默认口径，已记录为模型迭代项；唤醒项是否应改为不随恐慌衰减，属于待评估的建模选择。此外重构前三套策略在 840 个场景中由分群沟通 100% 夺冠，排序由常数写死，本轮是针对这一缺陷的重做。

4.5 参数敏感性

市场跌幅必须真实影响模拟结果，这是本项目的核心验收要求。在固定种子与固定策略的条件下，跌幅从 10% 增至 30% 时，不主动沟通情形下的恐慌峰值由 19.3% 升至 52.4%，卖出倾向由 6.1% 升至 23.3%，流失风险由 13.6% 升至 15.8%，三项指标均未出现反向下降。同一区间内推荐策略由「不主动沟通」切换为「统一风险提示」，说明推荐结果对冲击强度敏感。需要如实说明的是：分群差异化沟通的流失率在 20% 到 30% 之间出现 0.0005 的极小反向波动，量级在千分之一以下，已记录为模型迭代项。

市场跌幅	推荐策略	推荐策略恐慌峰值	基线恐慌峰值	基线卖出倾向	基线流失风险
10%	分群差异化沟通	2.6%	19.5%	5.1%	28.3%
20%	分群差异化沟通	18.1%	36.7%	10.3%	29.1%
30%	分群差异化沟通	36.1%	54.7%	22.7%	30.3%

表 8 跌幅敏感性（种子 20260830，300 名客户，10 个时间步）

持续时间的处理方式是把总时长映射为每段粒度，并让冲击的持续性随总时长变化。24 小时、48 小时与 72 小时对应每段 2.4、4.8 与 7.2 小时，压力衰减随总时长增长而变慢、峰值相应抬高，不主动沟通情形下的恐慌峰值分别为 19.3%、19.7% 与 19.8%，方向一致且可解释。需要再次说明：在现有参数下压力峰值恒定出现在首个时间步，因此这里的差异体现在峰值高度与衰减速度，而不是峰值位置。

4.6 消融实验与对照基线

为了说明每一层的贡献，引擎提供四个消融开关，分别关闭心理层、传播层、记忆层与合规层，其余条件不变。关闭记忆层时基线恐慌峰值从 19.3% 降至 6.0%，说明跨时间步的情绪留存是恐慌累积的主要来源；关闭传播层时降至 16.3%，相邻客户的情绪传导贡献约 3.0 个百分点；关闭心理层时降至 17.9%。合规层只作用于带违规草稿的策略，因此对基线策略没有影响，但关闭它会让统一风险提示策略的恐慌峰值从 17.3% 上升到 22.7%——统一风险提示的草稿含「务必立即行动」「一定反弹」等违规表达，合规拦截会把这些表达在模拟中的情绪放大通道清除。这正说明合规拦截真实改变了模拟结果，而不只是改写一段展示文本。

关闭层	基线恐慌峰值	基线卖出	基线流失	Δ 恐慌 (基线)	统一提示恐慌峰值	Δ 恐慌 (统一提示)
完整模型	19.3%	6.1%	13.6%	基准	17.3%	基准
关闭心理层	17.9%	4.5%	17.1%	-1.4 个百分点	16.0%	-1.3 个百分点
关闭传播层	16.3%	5.5%	13.5%	-3.0 个百分点	14.3%	-3.0 个百分点
关闭记忆层	6.0%	4.7%	13.1%	-13.4 个百分点	4.0%	-13.3 个百分点
关闭合规层	19.3%	6.1%	13.6%	0	22.7%	+5.4 个百分点

表 9 四层消融实验 (10% 冲击, 基线策略, 种子 20260830)

对照基线用于回答本方案的必要性。我们实现了四种对照模式：仅模型、模型加知识检索、单智能体与双层模拟。需要如实说明三点。第一，前两种模式在未配置模型密钥时按内置关键词规则近似排序，不调用任何模型，因此不是模型表现，不能作为能力对照结论，表中已标注为降级实现。第二，排序一致率必须按场景分别报告：在 5% 与 20% 档，单智能体与本方案一致率为 100%，但那只是两者都选择不干预的必然结果；在 50% 档，文本类模式与本方案的一致率仍有 66.7%，单智能体降到 33.3%。因此不能只用一格数字下一般性结论，正文表格给出了三档场景的完整结果。第三，稳定性指标衡量的是更换随机种子后排序是否保持不变，而不是同种子重复运行；在当前效用权重下该指标在 210 组检验中有 198 组恒为 1，接近退化为常数，因此只作记录、不作为能力证据。

对照模式	推荐策略	排序一致率	种子重采样稳定性
仅模型（无模拟，降级实现）	统一风险提示	33.3%	不适用
模型加知识检索（无模拟，降级实现）	统一风险提示	33.3%	不适用

单智能体（无个体状态与传播）	不主动沟通	100%	1.0
双层模拟（本方案）	不主动沟通	基准	1.0

表 10 四种对照模式在默认场景（10% 跌幅）下的比较

市场跌幅	仅模型（降级）	模型加知识检索（降级）	单智能体	双层模拟（本方案）
5%	统一风险提示（一致率 33.3%）	统一风险提示（一致率 33.3%）	不主动沟通（一致率 100%）	不主动沟通
20%	统一风险提示（一致率 33.3%）	统一风险提示（一致率 33.3%）	不主动沟通（一致率 100%）	不主动沟通
50%	统一风险提示（一致率 66.7%）	统一风险提示（一致率 66.7%）	统一风险提示（一致率 33.3%）	分群差异化沟通

表 11 三档冲击下的实测对照（时长 24 小时、步数 10、种子 20260830）

据此，本节把论证重心放在消融实验，而不是文本类对照。关闭记忆层使基线恐慌峰值从 19.3% 降至 6.0%、关闭传播层降至 16.3%，这两项直接说明「跨时间步的记忆」和「客户之间的情绪传导」是模型不可省略的部分，而这两层恰恰是纯文本方法无法提供的。至于「仅模型」与「模型加知识检索」两种模式，在未配置模型密钥的前提下只是占位对照，材料已如实标注为降级实现，不作为能力结论；正式版本需要在固定模型、固定提示词与固定温度下重复运行若干次后重新比较。

4.7 合规语料评测

我们构建了 32 条带标签的合规评测语料，其中应当阻断的 11 条、应当复核的 10 条、合规的 11 条。规则引擎对禁止性样例的召回率为 100%，对待复核样例的召回率为 90%，综合召回率 95.2%，对合规样例的误拦截率为 0。唯一一条漏检样本属于待复核类别，其语义依赖上下文判断，已被纳入后续规则迭代清单。需要如实说明三点。第一，这批语料与规则由同一团队在同一轮工作中产出，属于样本内自检，不构成独立验证。第二，32 条的样本量偏小，且缺少同义改写、长句嵌套、隐含承诺、否定套否定和依赖上下文等难例，因此上面这些比率主要用于工程回归，不代表生产环境下的泛化能力。第三，正式对外引用前需要补充由其他成员独立标注的盲样本集重做混淆矩阵，并按错误类型逐条列出漏检与误拦截样本——列出错误案例比展示满分更有说服力。

4.8 一次完整的业务运行案例

为了说明系统在实际业务里怎么用，这里给出一次完整运行。场景是市场当日下跌 30%、预计持续 48 小时，任务是分析持有高波动产品的客户并给出沟通建议。

****第一步，理解目标并筛选客户。**** 系统从这句自然语言里抽出跌幅 30%、持续 48 小时两个关键参数，再按高波动回撤客群的口径筛选：候选池共生成 900 名合成客户，其中 300 名同时满足「持有高波动产品」和「基准冲击下持仓弹性不低于 0.8」两个条件，被选为目标客户；另外 525 名未命中，这个数量在界面和审计里都会标注。本次命中充足，因此不需要按回撤补足。

****第二步，生成画像与关系网络。**** 300 名目标客户分布在五类原型上，各自带有六项心理参数，并由心理特征与所持产品共同算出一个持仓弹性，因此在同一场下跌中受损程度各不相同。系统同时建立三类客户关系，供后续的情绪传导使用。

****第三步，生成策略并做合规检查。**** 系统形成三套候选沟通方案，草稿先送合规检查。其中统一风险提示的草稿命中「务必立即行动」与「一定反弹」两处违规表达，被判定为诱导性紧迫表达与绝对化收益断言，随即拦下并改写为合规版本；同时该方案的话术刺激强度在后续推演中归零——被拦下的表达不会发出去，因此也不产生情绪放大效应。另外两套方案的草稿未触发阻断规则。

****第四步，群体推演与方案比较。**** 三套方案在相同客户、相同随机种子下分别推演 10 段，结果如下。

方案	综合推荐度	恐慌峰值	期末卖出	期末流失	合规结论
统一风险提示	4.68	45.8%	11.3%	10.9%	草稿 2 项违规，已拦下改写
分群差异化沟通	4.20	48.9%	5.6%	8.6%	无草稿违规
不主动沟通	0.00	53.0%	27.8%	16.1%	无草稿违规

表 12 案例场景下三套方案的实测结果（跌幅 30%、持续 48 小时、300 名客户、种子 20260830）

按综合推荐度排序，统一风险提示胜出：它的风险改善最明显，而人力成本远低于分群沟通。需要说明两点。一是该方案原本的违规话术已被拦下，参与推演的是改写后的合规版本，因此上面的数值反映的是合规版本的预期效果，不是违规话术的效果。二是这个结论随场景变化——把跌幅换成 5% 时推荐「不主动沟通」，换成 50% 且持续 72 小时时推荐「分群差异化沟通」，变化方向见 4.3 与 4.4。

****第五步，输出可执行的联系队列。**** 系统按每位客户在整段推演中的峰值暴露排序，得到优先联系名单：高风险 67 名、中风险 229 名、低风险 4 名。排在首位的是 C-1012，推演期内峰值风险 56%、持仓回撤 33.7%，系统同时给出这位客户的沟通渠道、触达时机与建议话术。之所以用峰值而不是期末值排序，是因为干预生效之后大多数客户的期末状态都会回落，按期末值排会得到一份几乎人人低风险的名单，失去业务价值。

整个过程每一步都写入审计：场景参数、工具序列、每步耗时、命中的合规规则与规则版本、随机种子。导出的报告由同一份数据生成，与界面口径一致。

4.9 界面与运行实测

下面五张截图取自本地开发环境的一次真实任务，输入为市场今天下跌 30%，分析持有高波动产品的客户，生成三套沟通方案，模拟未来 48 小时的客户群体反应，并指出应当优先联系谁。任务在规则模式下完成，该次实测首帧反馈约 0.35 秒、端到端 0.4 秒，本地引擎复算耗时十余毫秒，与服务端返回的聚合签名一致。需要说明的是：界面上的具体数值会随每次运行的环境负载略有波动，对外引用请以 `artifacts/metrics/latest.md` 中的指标快照为准，同版本的复测值为首帧 432 毫秒。




图 5 智能任务中心：规划步骤、工具轨迹与执行概览




图 6 客户洞察中心：优先联系名单与一人一策建议




图 7 群体行为沙盘：三套策略对比与分群传播网络回放




图 8 策略与审计：结论卡、方案对比与合规发现

技能名称	技能描述	技能等级	技能状态	审批记录
技能1	技能描述1	技能等级1	技能状态1	审批记录1
技能2	技能描述2	技能等级2	技能状态2	审批记录2
技能3	技能描述3	技能等级3	技能状态3	审批记录3
技能4	技能描述4	技能等级4	技能状态4	审批记录4
技能5	技能描述5	技能等级5	技能状态5	审批记录5
技能6	技能描述6	技能等级6	技能状态6	审批记录6
技能7	技能描述7	技能等级7	技能状态7	审批记录7
技能8	技能描述8	技能等级8	技能状态8	审批记录8
技能9	技能描述9	技能等级9	技能状态9	审批记录9
技能10	技能描述10	技能等级10	技能状态10	审批记录10
技能11	技能描述11	技能等级11	技能状态11	审批记录11
技能12	技能描述12	技能等级12	技能状态12	审批记录12
技能13	技能描述13	技能等级13	技能状态13	审批记录13
技能14	技能描述14	技能等级14	技能状态14	审批记录14
技能15	技能描述15	技能等级15	技能状态15	审批记录15
技能16	技能描述16	技能等级16	技能状态16	审批记录16
技能17	技能描述17	技能等级17	技能状态17	审批记录17
技能18	技能描述18	技能等级18	技能状态18	审批记录18
技能19	技能描述19	技能等级19	技能状态19	审批记录19
技能20	技能描述20	技能等级20	技能状态20	审批记录20

图 9 技能与审批：候选技能、指标快照与人工审批记录

五、创新点

本项目的创新点分为一条主创新与四项支撑创新。主创新回答「这个产品能做什么别的工具做不到的」，支撑创新回答「为什么它能做到、且结果可以被信任」。

5.1 主创新：取数结果直接进入行为推演，把「有多少」推进到「会怎样」

把自然语言转成 SQL 的工具已经不少，但它们的终点都是「给一张表」。在客户营销场景里，业务人员拿到名单之后真正要决策的是下一步：这批客户要不要联系、用什么话术、会不会引发投诉或流失。我们把取数与行为推演接成一条链路——问数结果页提供「用这批客户跑一次推演」的入口，取到的客户群体直接进入群体行为沙盘，按时间步推演他们的恐慌、卖出倾向、投诉与流失风险。

这条链路改变了取数的用途：它从「查数」变成「决策的前半段」——先看有多少人符合条件，再看对这批人做某件事会发生什么，最后才决定是否真的去做。这也是我们理解的赛题意图：不是做一个更快的报表工具，而是用智能体把客户营销里的感知、决策与执行串起来。

支撑这条主创新的还有四项设计，列在下面几节：把沟通策略参数化并交给引擎搜索、把模型与数值引擎的职责严格分离、把合规做成模型绕不过的硬边界，以及用可复现的评测体系而非主观描述来证明效果。

5.2 主创新（下游）：在触达客户之前，预演客户群体的反应

多智能体行为模拟在金融领域的常见用法是预测市场：让不同风格的交易者博弈，推演价格冲击。我们把同样的思路转向客户经营，让虚拟客户对服务策略作出反应。这一转向带来的差异是评价对象的变化：市场模拟关心价格，客户模拟关心的是接受、信任、投诉与流失。项目显式建模了客户的从众效应、情绪扩散与分群差异，三类关系边分别代表相似性、社交影响与统一服务触达，在 300 名客户下生成约 900 条可复现的关系边参与传播计算，并纳入消融实验验证其贡献。

这条主线由四个相互咬合的机制组成，缺一不可。

- 客户级状态建模：每位客户有自己的六项心理参数、持仓弹性与历史状态，不是把客群当成一个平均值。同一场下跌下，不同客户的恐慌、卖出与流失各不相同。
- 三类关系网络上的情绪传导：相似性、社交影响与统一服务触达三类关系边参与邻居状态更新，因此情绪会扩散、会放大，也会因为关键节点被干预而收敛——这是只看单个客户的画像工具给不出的。

- 策略作为可干预变量：三套候选沟通方案各自改变触达覆盖率、人工深度与话术贴合度，模拟回答的是「换一种沟通方式，客户反应会怎么变」，而不是只描述客户现状。

在模拟中，干预生效之后客户的期末恐慌会回落到接近零，如果按期末状态给客户排序，就会得到一份人人低风险的名单，失去业务价值。我们改为记录每位客户在整个模拟窗口内的峰值风险暴露，并以此为口径生成干预队列与优先级，同时保留逐时间步状态用于回放。这项调整让系统的输出从描述性指标变成可执行的行动清单。

四者合起来的结果是：把客户服务策略的评估节点从「触达之后」前移到「触达之前」，并且在同一个沙盘里同时回答「该不该发、发给谁、怎么说、大概会怎样」。

5.3 支撑创新一：沟通策略的参数化建模与引擎侧搜索

策略比较类功能最容易出现的缺陷是结论被写死：三套方案只差几个常数，而排序公式恰好只包含其中一套占优的维度，于是无论什么场景都是同一套方案获胜。本项目在早期版本存在这一缺陷（840 个场景中由分群沟通 100% 夺冠），重构后改为参数化建模：策略由触达覆盖率、人工深度、内容个性化三个杠杆定义，其余参数由杠杆推导；安抚经逐客户门控生效，覆盖率因此成为真实输入；推荐顺序由净效用在每个场景算出，净效用等于避险收益减去触达成本与唤醒成本。三套锚点退化为参数空间中的三个点，引擎另外在该空间做 27 点网格搜索。需要如实说明的是：效用权重是业务参数而非模型参数——避险收益与触达成本量纲不同，二者的兑换率无法从合成数据估计，只能由业务方设定；因此我们的结论只建立在与权重无关的结构性质上（跌幅越大、推荐方案的人工深度不下降，90 条场景序列零违反），而把夺冠配比连同权重敏感性曲面一并披露。另有两点边界：搜索结果只按参数直接评估，尚未生成草稿文本、也未经合规审查，因此不作为可执行推荐；异步任务链路与同步调试接口均已开启该搜索。

5.4 支撑创新二：模型与数值引擎职责分离

通用智能体项目常见的做法是把全部判断交给模型，代价是不可复现与不可审计。我们把模型限制在它擅长的环节：理解目标、规划步骤、抽取参数、起草策略、

解释结果；把大规模群体模拟与合规判定交给确定性代码。由此得到两个直接好处：同一场景与种子必然复现，聚合签名可以像单元测试一样做回归；模型措辞的变化不会改变数值结论，审计时可以把模型版本与规则版本分开追溯。

5.5 支撑创新三：合规作为不可绕过的硬边界

合规检查在本项目中不是模型的一环，而是位于模型之外的执行器。规则以注册表形式管理，附带否定语境识别与适当性矩阵。关键设计是：策略草稿在进入数值模拟之前先过合规审查，命中阻断级规则时既强制改写为合规版本，又清除该违规话术在模拟中的情绪放大通道。因此合规拦截会真实改变模拟结果，而不是只改写一段展示文本——关闭合规层会让统一风险提示策略的恐慌峰值上升 5.4 个百分点，这一差异在消融实验中可复现。规则集同时服务于模拟流程与独立的检查接口，避免出现两套口径。我们把这一点视为智能体进入金融业务的前置条件。

5.6 支撑创新四：可验证的评测体系

项目建立了四类可复现的评测材料：20 个标准业务任务用于衡量链路完整率与场景抽取一致率，630 个参数的扫描场景用于检验沟通策略推荐的结构性质与权重敏感性，32 条带标签的合规语料用于衡量召回率与误拦截率，四个消融开关与四种对照模式用于说明各层贡献与方案必要性。所有指标由脚本自动生成并记录版本号、规则版本、随机种子与样本量。我们已经移除了「规划成功率」这类在未接入模型时完全无法失败的指标，并新增了跨效用权重的单调性检验；但仍需如实说明：剩余指标里有少数与标定目标存在耦合（例如断言三种方案都能夺冠，其配比随权重变化），这类指标只能作为回归守卫，不构成独立验证，已在口径说明中标注。

六、可行性分析

6.1 工程可行性

系统采用 TypeScript 全栈实现，前端为 React，服务端运行在 Cloudflare Workers 之上，持久化使用 D1，系统的场景配置与客户字段采用显式契约（见 2.4、3.1 与第五章），官方数据到位后只需把字段映射到既有契约，不需要改动引擎结构；具体映射工作量取决于官方数据的实际格式，这一点要到数据到手后才能确认。

数值模拟的计算量很小：1000 名客户 20 个时间步的完整模拟在十几次采样中耗时为 59 至 82 毫秒，300 名客户 10 个时间步为 11 至 26 毫秒，单次任务的耗时瓶颈不在引擎侧。工程侧已建立自动化测试与指标脚本，静态检查、类型检查与构建均通过，改动可以持续回归。

6.2 数据可行性

在官方数据到位之前，系统使用合成脱敏数据完成能力验证，客户规模、原型分布与心理参数均可通过种子复现。客户画像所需的字段是交易记录、持仓结构、服务记录与反馈，这些字段在券商内部系统中有稳定来源。数据到位后的主要工作是校准，而不是重建：心理参数的取值区间与原型聚类结果需要用真实分布重新拟合，而引擎结构、规则集与接口契约不需要改动。

6.3 合规与部署可行性

产品只提供分析与建议，不自动触达真实客户、不执行交易，高风险动作必须经过人工审批。合规规则、适当性矩阵与审计留痕在架构上位于模型之外，规则版本与模型版本分开记录，便于接受合规部门审查。部署形态支持独立部署，也可以通过 API 或微前端嵌入既有工作台，不需要替换券商现有的 CRM 系统。模型接入采用 OpenAI 兼容接口，本地开发使用环境变量文件，部署使用平台密钥管理，密钥不进入代码仓库。

6.4 成本与性能

确定性数值模拟不产生模型调用成本，模型调用集中在目标理解、场景抽取、策略起草与结果解释四个环节，单次任务调用次数固定，成本可控。进度反馈采用增量事件推送而非轮询，首帧耗时与模型延迟解耦，在未配置模型密钥的规则模式下首帧实测为 0.35 至 0.6 秒（视环境负载），端到端在 1 秒以内。模型超时与不可用、格式错误、模拟失败三类异常都有降级路径；知识检索在命中不到相关内容时降级为无检索并标注，不会导致任务静默失败。

七、风险与合规声明

- 数据声明：初赛阶段全部使用合成与脱敏数据，不包含任何真实客户信息，不宣称真实客户行为的预测准确率；指标仅用于说明系统在给定口径下的行为一致性与稳定性。
- 业务边界：系统只输出分析、建议与模拟结果，不自动触达真实客户，不执行任何交易或产品申购动作；涉及高风险动作的环节一律要求人工审批。
- 合规边界：合规规则、适当性矩阵与审计留痕位于模型之外，模型无法绕过；命中阻断级规则时强制改写或拦截，并把处置结果写入审计记录。
- 模型使用：不保存也不展示模型的原始思维链，界面只呈现因素权重、数据证据、规则命中与结构化执行轨迹；模型输出经结构校验后才进入流程。
- 学习机制：无审批的在线学习处于关闭状态，人工反馈只用于生成候选技能，不会自动修改引擎参数或策略权重；候选技能须经人工批准后才会被后续任务复用，同名技能版本号递增因而支持回滚到上一版本。
- 降级声明：未配置模型密钥或模型调用失败时，系统进入规则模式或确定性降级，并在界面显式标注执行模式，不将规则结果包装为模型结果。
- 评测声明：三档评测语料（50 条标准问句、15 条留出问句、12 条能力边界问句）与对照查询均由团队自写，材料中的准确率是自造数据与自造语料上的自测结果，不代表真实数据集上的准确率；官方问答对发放后我们会重跑评测脚本并更新材料。样本内语料在开发过程中被反复运行过，数字偏乐观，留出集与能力边界集是更诚实的参照；能力边界集当前有 2 条超范围问句仍给出了答案，已列为已知缺口。
- 元数据声明：九张表的列级定义由我们按维度建模自行设计（赛题给出了表清单但未给列定义），与官方数据集可能存在字段差异；官方数据到位后只需替换数据装载层与列映射，取数链路、安全围栏与评测脚本不需要改动。
- 后续计划：接入官方数据集后，用真实分布校准客户画像与心理参数，并在材料中同步更新指标口径与结论。